

非特定テレビ視聴履歴データを用いた テレビ視聴行動クラスタリング手法の構築と評価

真弓 大輝^{†1}

奈良先端科学技術大学院大学

松田 裕貴^{†2}

岡山大学

松田 裕貴^{†3}

読賣テレビ放送株式会社

横田 哲弥^{†4}

読賣テレビ放送株式会社

榊原 太一^{†5}

読賣テレビ放送株式会社

安本慶一^{†6}

奈良先端科学技術大学院大学

概要

本研究では、テレビ視聴履歴データを用いた最初のデジタルツインの構築を目指す。近年、メディア環境の変化に伴い、視聴者の行動理解の重要性が増している。テレビの視聴行動に関するデジタルツインを構築することで、視聴データから得られるリアルタイムの情報をもとに視聴行動のシミュレーションが可能となり、視聴者の嗜好や行動パターンを仮想的に再現し、広告やコンテンツ制作、マーケティング戦略の最適化に利用することができる。本研究では、個人を特定しない形式で大規模に収集された非特定テレビ視聴履歴データから、ユーザの視聴行動分類手法を確立し、視聴傾向に基づいた視聴行動シミュレータを構築する。本稿では視聴履歴データを詳細に分析し、テレビ視聴に特化した独自の特徴量を生成することで、視聴傾向を分類するモデルを作成し、モデルの妥当性を評価した。その結果、視聴傾向分類では各クラスで生活様式やユーザ層が説明可能となり、さらに平日と休日の視聴傾向分類モデルは、ともにF値0.95程度を記録しており、高精度に予測可能であることが示された。この新しいアプローチは、テレビ視聴のデジタルツイン構築に向けた新たな知見を提供し、データ駆動型のメディア戦略における新たなアプローチへの道を開くものである。

1. はじめに

近年ネット配信番組に代表されるサブスクリプションサービスの需要が高まっている。一方で、テレビの視聴者

数は減少傾向にあるもののテレビは依然として多くの家庭における主要な情報源や娯楽として利用されており、その影響力は大きい。最近ではインターネットに接続されたテレビ (Connected TV, CTV) の普及が進み、各放送局はテレビの視聴履歴データを収集・蓄積し放送サービスの向上を目指している。CTVによって取得される視聴履歴データは、本人の許諾や個人情報の有無により、表1に示すように、3つに分類されている (オプトイン型特定視聴履歴データ、オプトイン型非特定視聴履歴データ、オプトアウト型非特定視聴履歴データ)。このデータの取り扱い、一般社団法人放送セキュリティセンターが公表した「オプトアウト方式で取得する非特定視聴履歴の取扱いに関するプラクティス [1]」に基づき、放送局により収集・活用が進んでいる。プラクティスによって放送局間でのデータ交換が認められたことにより、これまで在阪4局の放送局間では2回のデータ交換が行われており、個別の放送局が収集したデータ単体では難しかった新たな価値を生み出すことが期待されている。これまでに、オプトイン型非特定視聴履歴データは視聴傾向の研究や視聴パターンの分類手法の提案など様々な研究が行われてきたが、収集規模が小さくデータの利活用は難しいことが知られている。一方で、オプトアウト型非特定視聴履歴データは、個人を特定しない形式で自動的に収集されるため、収集規模が非常に大きく、放送局のみならずスポンサーや広告代理店からもビッグデータとしての活用が期待されている。

また現実空間の情報を取得し、仮想空間内に物理的な対象や挙動をモデル化し、再現することでシミュレーションや分析に利用されるデジタルツインが様々な分野で活用されている [2, 3, 4]。テレビの視聴行動に関するデジタルツインを構築することで、視聴データから得られるリアルタイムの情報をもとに視聴行動のシミュレーションが可能となり、視聴者の嗜好や行動パターンを仮想的に再現し、広告やコンテンツ制作、マーケティング戦略の最適化に利用することができる。しかし、このようなテレビ視聴行動に関するデジタルツインの構築は、視聴行動のモデル化や視聴

Conference Manuscript Format for Academy of Behavior Transformation by AIoT (BTI)

^{†1} DAIKI MAYUMI, Nara Institute of Science and Technology

^{†2} YUKI MATSUDA, Okayama University

^{†3} HIROKI MATSUDA, Yomiuri Telecasting Corporation

^{†4} TETSUYA YOKOTA, Yomiuri Telecasting Corporation

^{†5} TAICHI SAKAKIBARA, Yomiuri Telecasting Corporation

^{†6} KEIICHI YASUMOTO, Nara Institute of Science and Technology

表 1 視聴履歴データの分類

種類	データの特徴				本論文で扱う データセット
	本人許諾	個人情報	データの多様性	データの数	
オプトイン型特定視聴履歴データ	有り	有り	低い	少ない	-
オプトイン型非特定視聴履歴データ	有り	無し	低い	少ない	-
オプトアウト型非特定視聴履歴データ	無し	無し	高い	多い	○

傾向の分析に留まっており、具体的な実現には至っていない。従来の研究は個々の視聴者に焦点を当てている一方で、ビッグデータ解析を通じて全体的なトレンドやパターンを把握するデータ駆動型のアプローチは、データに基づいた意思決定を可能にし、効果的なマーケティング戦略の構築に寄与する可能性があるが、視聴傾向の分類やデジタルツインの構築に関する研究はまだ初期段階である。

そこで本研究では、個人を特定しない形式で大規模に収集された非特定テレビ視聴履歴データから、テレビ視聴行動のデジタルツインを実現することを目的として、ユーザの視聴行動分類手法を確立し、視聴傾向に基づいた視聴行動シミュレータを構築する。ユーザの視聴傾向を分類するため、視聴履歴データからテレビの視聴に関する独自の特徴量を生成し、視聴傾向の分類を行った。また分類されたクラスの妥当性を評価するために専門家の意見をもとに、各クラスを説明可能な形で定義した。さらに視聴傾向分類モデルを構築し評価した結果、平日と休日の両モデルでF 値 0.95 以上の高い予測を可能とし分類モデルの有効性を示した。本研究の成果は、テレビ視聴行動のデジタルツイン実現への重要な一歩となる。

2. 関連研究

デジタルツイン技術は、様々な分野での応用が進んでおり、リアルタイムデータを活用したシミュレーションや分析が新たな価値を創出している。またテレビ視聴履歴データの活用においても視聴行動の分析が行われている。

2.1. デジタルツイン技術の動向

デジタルツイン技術は、製造業 [5, 6, 7] やデータセンサー [8, 9, 10] などの産業分野だけでなく、医療 [11, 12, 13]、都市計画 [14, 15, 16] など様々な領域で活用されている。この技術は、物理的な物体やシステムをデジタル空間に再現し、シミュレーションや分析に利用されている [2, 3, 4]。特に、IoT (Internet of Things) 技術と組み合わせることで、センサーデータをリアルタイムで収集し、迅速な意思決定を可能にしている。

スマートシティ [14] では、急速に増加する経済活動や人口、気候変動への対応が求められる中、資源管理の困難さが

顕著となっている。デジタルツインは、物理世界の仮想モデルとして機能し、都市管理における効率化と最適化を実現するソリューションを提供している。例えば、デジタルツインの高度道路交通システムへの応用である。Rudskoy ら [15] は、デジタルツインと機械学習を活用した予測分析のシミュレーションを行うためのモデルを提案している。また Kumar ら [16] は、ドライバーの意思予測を通じて、交通渋滞を削減するデジタルツインのアプローチを提案している。ヘルスケア分野では、患者の健康状態を基にデジタルツインを生成し、リハビリテーション計画や進捗管理を行ったり [12]、パーソナライズされた臨床試験のために、サンプル効率の高いデジタルツイン生成手法を提案している [13]。さらに、デジタルツインは物理空間とデジタル空間の同時マッピングを可能にし、ロボティクスやデータセンシング分野においてもその有効性が確認されている [17, 18]。

このように、デジタルツイン技術は多様な分野での応用が進み、今後もこの技術は進歩することが予想される。またテレビ視聴データの解析においても、デジタルツインの導入が視聴行動理解に新たな視点を提供する可能性がある。

2.2. テレビ視聴データの活用方法

テレビ視聴データは、視聴者の行動パターンや好みを理解するための重要な情報源となっている。しかし、これまで十分なテレビ視聴データがなかったため、グループの嗜好は個人嗜好の単純な集計でモデル化されることが多かった [19, 20, 21, 22, 23]。これらの手法によって一定の成功を収めているものの、グループ内の力学や相互作用を十分に把握できていない。また従来の視聴行動研究の多くは、数百人規模の自己報告データに依存しているため、データ数が少なく詳細な分析ができなかった [21]。

一方でテレビ視聴データ以外のアプローチとして、約 17 万人のユーザ、24,000 本の映画、440 万件の評価を含む Moviepilot のデータセットを使用し、多くのグループ推薦手法が提案されている [24, 25, 26]。また Senot らの研究 [20] では、テレビ視聴の実際の大規模データセット（約 15,000 人のユーザと 3,000 万回のテレビ番組視聴記録）も活用されているが、グループ活動が不十分であるため実際に分析に利用された世帯はわずか 136 世帯に限られている。

米国の大規模な視聴者パネルを用いた研究とグループの視聴パターンが調査されている。定への一般化にはまだ課題が残っている。テレビ視聴データを用いた研究 [28] では、ネル選択が提供される番組内容に影響され、さらに社会経済的グループによる嗜好動に大きく影響することが示された。この矢アの予測や新しいチャンネルの導入時の視に応用されている。このようなデータ駆動は、視聴者の満足度を向上させる重要な要素である。

また我々の研究グループでは、放送局が特定テレビ視聴履歴データを用いた視聴行を行っている。松田らは、各放送局が収集した視聴履歴データを統合するための Non-1 マッチングアルゴリズム [29, 30] を考案し CM 視聴がその後のインターネット検索行動に与える影響について Google Trends から 1 時間ごとの検索クエリのトレンドを取得し CM のメタ情報と組み合わせることで CM ジャンルと検索寄与度の関係を調査している [31]。また吉村ら [32] は CM の完視聴率にどのような地域差が存在するのか分析している。このように視聴履歴データの活用が進められているが、非特定テレビ視聴履歴データを用いて視聴傾向を分類し、その分析結果を番組制作などに活かしていないのが現状である。

3. テレビ視聴に関するデジタルツイン構築のための合成視聴データの生成手法

本研究では、テレビ視聴行動をデジタルツインとして再現するため、「テレビ視聴行動シミュレータ」の設計と実装手法について詳細に述べる。提案する視聴行動シミュレータの全体構成を図 1 に示す。本シミュレータは、視聴者の視聴傾向をモデル化した「視聴者モデル」、IP アドレスの変化周期や回数を抽象化した「テレビ受信機モデル」、および視聴履歴データの収集プロセスを再現する「放送局モデル」の 3 つのモデルを基盤としている。これらのモデルを統合し、視聴行動を生成するエージェントモデルを構築することで、現実の視聴行動に近い合成視聴データを作成する。

3.1. エージェントモデル

エージェントモデルは、視聴行動を生成する中心的な役割を担う。視聴者モデルとテレビ受信機モデルを組み合わせることで、現実の視聴行動に基づく動的な視聴データ生成を可能にしている。

3.1.1 視聴者モデル

視聴者モデルは、視聴履歴データを基に視聴者の行動パターンを分類し、視聴傾向をモデル化する。視聴者の視聴傾向

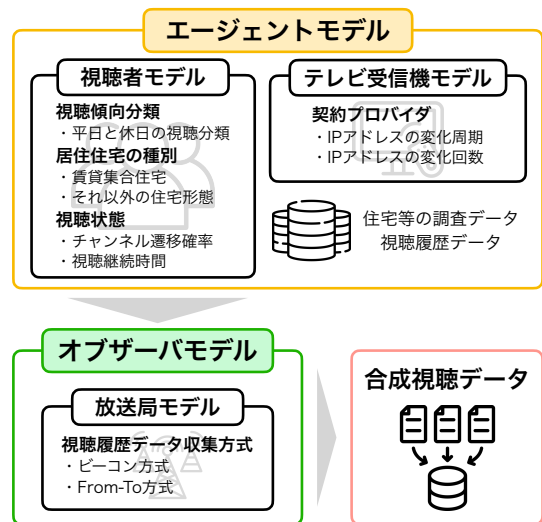


図 1 テレビ視聴行動シミュレータ処理の流れ

向を理解することで、実際の視聴傾向に近い合成視聴データを生成可能としている。視聴傾向の分類については、後のセクションで具体的な手法と結果について詳しく説明する。

テレビ視聴履歴データは、インターネット結線されたテレビ受信機を対象に収集されている。このデータには、家庭内で共有されるグローバル IP アドレスが含まれ、集合住宅では 1 つのグローバル IP アドレスを複数の住居で共有している場合が多い。エージェント生成時には、集合住宅や戸建住宅、分譲集合住宅など視聴者の居住形態を考慮する。

また在阪 4 局のテレビ視聴履歴データを用いて、視聴者が次にどのチャンネルに遷移するかを示す「状態遷移確率」や、視聴を開始したチャンネルをどの程度の時間視聴し続けるかを示す「視聴継続時間」を分析した。これらの分析結果を基に、視聴チャンネルの選択や継続時間を確率的に決定するモデルを構築する。

3.1.2 テレビ受信機モデル

テレビ受信機モデルは、IP アドレスの変化に関する特性を再現することを目的とする。視聴履歴データの分析から、同一テレビ受信機の IP アドレスが定期的に変化していることが確認されており、この変化は契約プロバイダやネットワーク環境に依存する。本モデルでは、視聴履歴データから得られた IP アドレスの変化周期や回数を反映し、実際のテレビ受信機の挙動を模倣する仕組みを実装した。これにより、現実のネットワーク環境を考慮した視聴データの生成を可能にしている。

3.2. オブザーバモデル

オブザーバモデルは、生成された視聴行動から視聴履歴データを精緻に再現するために設計された。具体的には、放

表 2 各放送局の取得方式と時刻データ正確性

放送局	A 局	B 局	C 局	D 局
方式	ビーコン	ビーコン	From-To	From-To
ビーコン間隔	60 秒	15 秒	-	-
開始時刻の正確性	正確	正確	正確	正確
終了時刻の正確性	60 秒以内の誤差	15 秒以内の誤差	正確	正確

送局が使用するデータ収集方式をモデル化し、視聴履歴データの生成プロセスを再現する。表 2 に示すように、放送局の視聴履歴データ収集方式は、ビーコン方式と From-To 方式の 2 種類に分類される。ビーコン方式は、視聴開始からビーコン送信が開始されるまでの間にチャンネル遷移が発生した場合、その間の視聴履歴が記録されない場合がある。この方式はサーバ負荷を軽減するための設計であるが、視聴行動と履歴データの間に乖離が生じる要因となる。本研究では、放送局ごとの特徴を反映したオブザーバモデルを構築することで、実際のデータ収集プロセスを模倣し、精緻な視聴履歴データを生成することを可能にする。

4. 非特定テレビ視聴行動データを用いた視聴傾向分類

非特定テレビ視聴履歴データを用いて、視聴傾向別に視聴者をクラス分類する手法を提案する。はじめに利用するデータと特徴量および視聴傾向の分析方法について説明する。また本分析において、クラスタリング結果に対するラベル付や考察は讀賣テレビ放送株式会社^{*1}の専門家の意見を参考にしている。

4.1. 視聴傾向分析の特徴量設計とクラスタリング手法

本分析では、在阪 4 局の非特定テレビ視聴履歴データおよび番組データ、総個人視聴率 (Persons Using Television, PUT) データを用いる。本分析に利用するデータ期間は、視聴習慣などが大きく変化するような大型イベントがない通常の放送期間である 2023 年 1 月 17 日～2023 年 3 月 31 日の 2.5 ヶ月間を用いた。対象期間の視聴台数は、約 144 万台であったため、本分析では連続視聴 6 時間を超えるテレビを除き、平日と休日に共通するテレビ台からランダムに 12,000 台を抽出し、視聴傾向分析を行った。

視聴傾向分析のためのクラス分類手法として、k-means クラスタリングを採用し、平日と休日それぞれ 6 クラスに分類した。クラス分類に用いた特徴量を表 3 に示す。これらの特徴量は、量的データと質的データが混在するため、前処理を行いスケールを合わせた。視聴時間に関する量的データは、標準化を行い、視聴チャンネルや視聴ジャンル等

の質的データは、One-Hot エンコーディングを適用し、クラス分類に適したデータに変換した。

次に特徴量間の多重共線性を避けるために、相関関係を分析した。特徴量間の相関関係を視覚化し、相関係数の絶対値が 0.8 以上の組み合わせを列挙した結果、冗長性があると判断された特徴量を削除した。さらにクラス分類における寄与度が低い特徴量を調べるために、各特徴量のクラス間での標準偏差を計算し、特徴量の寄与度を降順に並べた。本分析では寄与度が 5% 以下の特徴量を削除し、最終的に残った特徴量を用いて、再度視聴傾向の分類を行った。

4.2. 視聴傾向分類の結果

図 2 に平日における視聴傾向クラスの分類結果を示す。各時間帯における平均視聴時間を棒グラフで示し、テレビの視聴台数は折れ線で示している。以降では各クラスについて、グラフの傾向に基づいてどのような視聴者層であるかについて考察する。

クラス 1 は、「一人暮らしの若年層」と名付けられるクラスである。視聴時間は全体的に短めで、夜間に視聴が増加する傾向はあるが、大きなピークは見られない。テレビ視聴に対する依存度が低く、ニュースや情報番組を中心に、短時間で必要な情報を収集する傾向がある。若年層や働き盛りの世代は、仕事や学業、外出などで忙しく、長時間テレビを見る時間が取れない傾向がある。

クラス 2 は、「テレビファン層」と名付けられるクラスである。1 日を通して視聴時間が長く、特に朝 5 時から 10 時、また夜 19 時以降に視聴時間が増加する傾向がある。視聴する番組ジャンルも分散しており、多様な番組を満遍なく視聴している特徴がある。これはその時間帯に放送している番組ジャンルの割合に近い傾向を示している。また、朝 7 時台の落ち込みは、NHK を視聴している可能性が示唆される。

クラス 3 は、「情報番組・報道番組の多視聴層」と名付けられるクラスである。主に朝 5 時から夕方 18 時までの時間帯で視聴が集中し、情報番組やワイドショーの視聴時間が特に長いことが確認されている。7 時台や 19 時～22 時台は民放を見ていないが、23 時台は戻ってきているため、NHK の視聴を行なっている可能性が示唆される。

クラス 4 は、「中年や子育て世帯層」と名付けられるクラスである。1 日を通して継続的に視聴されている。早朝から日中にかけてはニュースや情報番組を視聴し、夜間はバラエティの視聴割合が多くなっている。また視聴台数は早朝から夜間にかけて一貫して高く、家庭のリビングなどの共有スペースでテレビを視聴する世帯が多く、特に中年や子育て世帯が該当すると考えられる。

クラス 5 は、「一般的に近い視聴層」と名付けられるクラスである。ここでの「一般的」とは、朝の視聴傾向が高く、

^{*1} <https://www.ytv.co.jp/>

表 3 視聴傾向分類で使用する特徴量

特徴量名	説明	単位/形式	利用特徴量
総視聴時間	指定期間内の総視聴時間の合計	分 (minutes)	✓
1 日の平均視聴時間	1 日あたりの平均視聴時間	分 (minutes)	-
視聴日数	指定期間内にテレビを視聴した日数	日数 (days)	✓
全日の視聴時間	全日の平均視聴時間 (6 時～0 時の範囲)	分 (minutes)	-
ゴールデンタイム	ゴールデンタイム (19 時～22 時) の平均視聴時間	分 (minutes)	✓
プライムタイム	プライムタイム (19 時～23 時) の平均視聴時間	分 (minutes)	-
主要視聴ジャンル	最も多く視聴された番組ジャンル	カテゴリ (ジャンル名)	✓
主要視聴チャンネル	最も多く視聴されたチャンネル	チャンネル ID	-
チャンネルの占拠率	各チャンネルの視聴割合	比率 (%)	✓
ジャンル毎の視聴時間	各ジャンルの視聴時間	分 (minutes)	✓
視聴ジャンル数	指定期間内に視聴したジャンルの数	数値 (integer)	-
主要視聴時間帯	最も多く視聴された時間帯 (時間単位で計算)	時間 (hour)	✓
活動的視聴時間	早朝や深夜の視聴時間 (5 時～9 時, 22 時～2 時)	分 (minutes)	-
平均 PUT 値	視聴頻度が高い時の平均 PUT 値	PUT 値 (float)	✓
高 PUT 時の視聴比率	PUT 値が平均以上の時間帯における視聴時間の割合	比率 (%)	-
低 PUT 時の視聴比率	PUT 値が平均未満の時間帯における視聴時間の割合	比率 (%)	-
PUT の平均値	期間内の PUT の平均値	PUT 値 (float)	✓
PUT の標準偏差	期間内の PUT の標準偏差	PUT 値 (float)	✓
PUT の最大値	期間内の PUT の最大値	PUT 値 (float)	✓
PUT の最小値	期間内の PUT の最小値	PUT 値 (float)	✓
PUT の中央値	期間内の PUT の中央値	PUT 値 (float)	-
PUT の最頻値	期間内の PUT の最頻値	PUT 値 (float)	✓

昼間の視聴が減少し、夜のゴールデンタイムに再び視聴時間が長くなるといった、一般的な視聴率に近い波形を表している。クラス 2 同様に視聴する番組のジャンルの偏りが少なく、ゴールデンタイムに音楽番組も視聴するなど多様な番組を満遍なく視聴している傾向を示しているが、クラス 2 ほど視聴時間は長くない。朝 10, 11 時台はスポーツの視聴割合が高いが、ゴールデンタイムのスポーツ割合は高くない。

クラス 6 は、「デジタルネイティブ層」と名付けられるクラスである。テレビ視聴に対する依存度が極めて低い傾向が見られる。主に夜間のみ短時間だけ視聴し、ニュースや情報番組を通じて必要最低限の情報収集を行なっている。テレビを主な娯楽手段とせず、スマートフォンや他のデジタルデバイスを主流にした生活スタイルが特徴として現れていると考えられる。

以上のように、提案する特徴量に基づいた視聴傾向分類により、各クラスに対して説明可能な傾向が認められ、適切なクラスタリング手法の確立に寄与することが示された。この手法を平日および休日においてそれぞれ適用し、それぞれ 6 クラスのラベルを生成した。

5. 視聴傾向分類の結果に基づく分類モデルの構築と評価

本章では、前章の視聴傾向分類の結果をラベルとして利用し、LightGBM を用いて視聴傾向を分類するモデルの構築と評価を行う。

5.1. 利用データと評価手法

本分析では、視聴テレビ台数 12,000 台の視聴データを用いて、視聴傾向を平日と休日それぞれ 6 クラスに分類するモデルと平日と休日のクラスを掛け合わせた 36 クラス分類モデルを構築した。データ全体の 8 割を訓練データ、2 割をテストデータとしてランダムに分割し、これを 10 回繰り返して各評価指標の平均値を算出した。これにより、データの分割によるばらつきを抑え、モデルの分類精度をより安定して評価できるようにした。

分類モデルには LightGBM を採用し、各試行の評価指標には正解率、適合率、再現率、F 値を使用した。ハイパーパラメータの最適化には、RandomizedSearchCV を使い、学習率、葉の最大数、最大深度などを調整し、精度向上を図った。ハイパーパラメータの最適化により、平日と休日の視聴傾向の違いをより正確に捉えられるようにし、視聴行動の特徴をより精緻に分類するモデルを構築した。

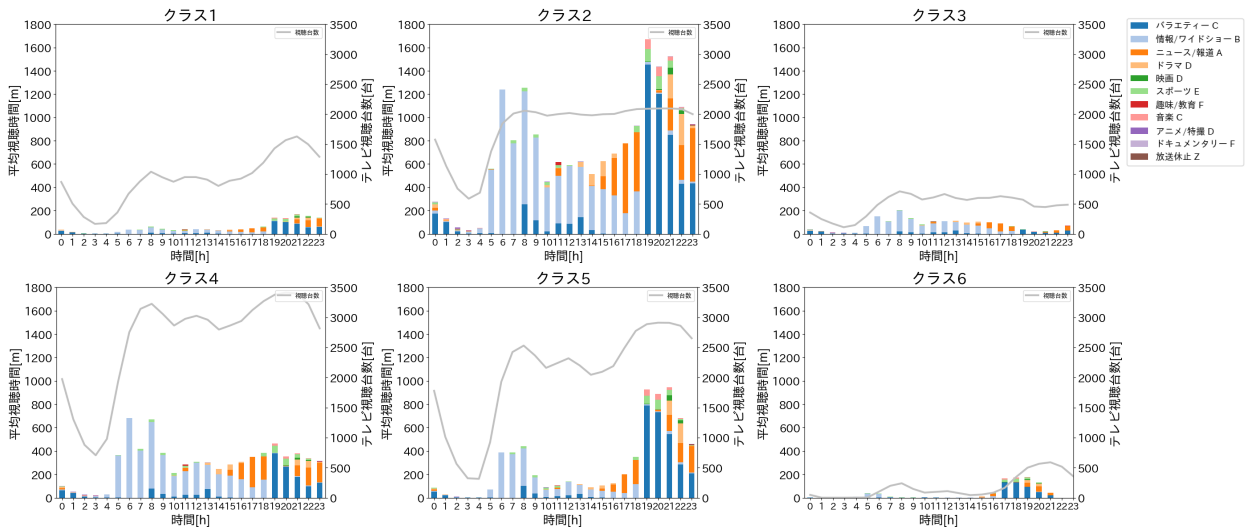


図2 平日のテレビ一台あたりの平均視聴時間と視聴ジャンル

5.2. 視聴傾向分類モデルの評価結果

表4に平日と休日のそれぞれの視聴傾向分類モデルおよび平日と休日を合わせたモデルにおける平均の分類結果を示す。平日モデルと休日モデルは6クラス分類で、平日と休日を合わせたモデルは36クラス分類を行った。平日モデルの評価結果では、正解率や適合率、再現率、F値の全ての指標で約0.95を達成し、安定した分類性能を示した。この結果は、平日の視聴傾向分類が高い精度で行われたことを示しており、モデルが平日特有の視聴パターンを効果的に捉えていることがわかる。

また休日モデルでは、さらに優れた結果が得られすべての評価指標で0.95を超える高いスコアが確認された。これにより、提案したモデルが平日および休日の視聴傾向に基づく分類タスクにおいて一貫して高い性能を発揮し、視聴行動のパターンを的確に捉えていることが示された。特に休日モデルが平日モデルを上回る性能を示した点は、視聴傾向における曜日別の特徴が存在する可能性を示唆している。

一方で、平日と休日を組み合わせた分類モデルでは、指標ごとに顕著な変動が見られ、F値は0.656となり低い結果となった。これは、平日および休日で異なる視聴傾向が一つのモデル内で統合されたことが影響していると示唆される。また、36クラスの各クラスに属するサンプル数に大きなばらつきがあるため、サンプル数の少ないクラスで分類が困難となり、全体の指標の低下に繋がった可能性がある。

これらの結果から、平日と休日の視聴傾向を分離したモデルの方が分類精度において優れており、視聴行動の複雑さや変動を反映する上でより有効であることが示唆された。

表4 視聴傾向分類モデルの評価結果

評価モデル	正解率	適合率	再現率	F 値
平日モデル	0.954	0.954	0.947	0.950
休日モデル	0.956	0.956	0.952	0.954
平日&休日モデル	0.828	0.712	0.627	0.656

6. ディスカッション

6.1. 視聴傾向の分類

最適な視聴傾向分類ができた要因として、視聴行動に特化した多面的な特徴量を生成した点が挙げられる。これにより、視聴時間帯や視聴番組のカテゴリなどの視聴パターンを詳細に反映することができ、各クラス間の視聴行動の違いを効果的に表現したと考えられる。特にテレビ視聴に特化した独自の特徴量を取り入れることで、視聴者が持つ多様な行動傾向を捉えることができ、精緻な分類を実現することができた。また平日と休日で視聴行動が異なることを前提に、それぞれ独立した分類を行った点も重要である。平日と休日の視聴行動に顕著な違いがあるため、曜日別にクラス分類を行うことで、視聴者の特定の時間帯や番組嗜好を反映した特徴が識別され、異なる視聴行動パターンをより明確に区別することが可能になった。さらに、PUT値を基に視聴傾向を補正することで、視聴時間が短いクラスと長いクラスの明確な区分が生まれ、視聴行動の多様性がさらに細分化された。最後に放送局の専門家による評価を取り入れたことで、各クラスが実際の生活習慣や視聴者属性に基づいた意味のある分類であることを確認した。専門家の知見を反映することで、データ駆動型の分類結果が実務的に有用であることが証明され、研究成果の信頼性が高

まった。これにより、データ駆動のクラスタリングと実務的な有効性の両面で信頼性の高い分類が実現されたと考えられる。以上により、本研究では視聴傾向を精緻に分類するための手法を確立したと結論づけられる。

6.2. 分類モデルの評価

本研究の平日・休日モデルの結果により、曜日によって視聴行動の違いが生じることが示唆された。休日モデルのスコアが平日モデルを上回った要因として、休日には視聴者の行動パターンがより明確に分類できる点が考えられる。例えば、休日には特定の番組カテゴリ（映画やドラマなど）に人気が集中し、視聴時間帯の傾向が偏ることが予想されるため、モデルが特徴を捉えやすくなる可能性がある。このような休日特有の視聴傾向が、モデルの高い評価につながったと考えられる。また平日モデルも高い精度を示しており、平日には視聴者が通勤時間帯や夜間のニュースなど視聴傾向が一定のパターンに従う可能性を示唆している。この安定した視聴行動が、モデルの分類性能を向上させたと考えられる。また正解率、適合率、再現率、F 値がほぼ同等であることから、予測結果に偏りがなく、全体的にバランスのとれた分類が行われていることが確認できた。

一方で、平日と休日を組み合わせた分類モデルでは、指標ごとに顕著な変動が見られ、F 値は 0.656 となり低い結果となった。この変動の要因の一つとして、各クラスに属するサンプル数の不均衡が挙げられる。特に 36 分類モデルでは、各クラスのサンプル数に大きなばらつきがあり、該当者がわずか 2 名のクラスも存在した。このような不均衡は、適合率や再現率に悪影響を及ぼし、サンプル数の少ないクラスにおいて、クラス特有の特徴を十分に学習できず正確な分類が難しくなったことが指標の低下に影響したと考えられる。また平日の視聴行動が休日と異なる傾向があるため、モデルがこれらの違いを一貫して分類することが困難となり、再現率および F 値が低下したと考えられる。

今後は、関西以外の地域や他の期間のデータセットを用いた評価を通じて、テレビの視聴分類モデルの汎用性を検証する。さらに、LightGBM 以外のアルゴリズムとの比較により最適なモデル構築を目指す。最終的には、視聴傾向に基づく番組編成や広告配信の最適化への応用を視野に入れ、実用的なアプローチの確立を目指す。

7. まとめ

本研究では、テレビ視聴行動に特化した特徴量を新たに設計し、これを用いてテレビの視聴傾向分類を行うことで、各クラスにおいて説明可能な分類を可能とした。またこれら結果を元に平日および休日のそれぞれに対して高精度な視聴傾向分類モデルを作成した。作成した分類モデルの妥

当性を検証した結果、平日および休日の個別モデルにおいては全ての指標で高い値を示し、モデルの有効性が確認された。一方で、平日と休日を統合した 36 クラス分類モデルでは、視聴傾向の複雑さや各クラスのデータの不均衡さが影響を与え、平日および休日の個別モデルと比較して精度が低下した。これらの結果より、視聴傾向の分類に基づくモデル構築手法によって、視聴者の多様な行動パターンを再現可能であることが示された。今後はこの視聴傾向分類結果に基づいた合成視聴データを生成し、実際の視聴データとの統計的な比較を行い、合成テレビ視聴データの有効性を示す。これにより、テレビ視聴行動のデジタルツイン実現に向けた有効なアプローチを提供し、今後の応用可能性とさらなる発展の可能性が期待される。

参考文献

- [1] 一般財団法人放送セキュリティセンター 視聴関連情報の取扱いに関する協議会：オプトアウト方式で取得する非特定視聴履歴の取扱いに関するプラクティス (ver2.3), https://www.sarc.or.jp/documents/www/NEWS/hogo/2024/optout_practice_ver2.3.pdf (2024).
- [2] Hughes, A.: Forging the digital twin in discrete manufacturing, a vision for unity in the virtual and real worlds, *LNS Research e-book* (2018).
- [3] Zhou, X., Liang, W., Yan, K., Li, W., Kevin, I., Wang, K., Ma, J. and Jin, Q.: Edge-enabled two-stage scheduling based on deep reinforcement learning for internet of everything, *IEEE Internet of Things Journal*, Vol. 10, No. 4, pp. 3295–3304 (2022).
- [4] Zhou, X., Xu, X., Liang, W., Zeng, Z., Shimizu, S., Yang, L. T. and Jin, Q.: Intelligent small object detection for digital twin in smart manufacturing with industrial cyber-physical systems, *IEEE Transactions on Industrial Informatics*, Vol. 18, No. 2, pp. 1377–1386 (2021).
- [5] Kritzinger, W., Karner, M., Traar, G., Henjes, J. and Sihn, W.: Digital Twin in manufacturing: A categorical literature review and classification, *Ifac-PapersOnline*, Vol. 51, No. 11, pp. 1016–1022 (2018).
- [6] Liao, S., Wu, J., Bashir, A. K., Yang, W., Li, J. and Tariq, U.: Digital twin consensus for blockchain-enabled intelligent transportation systems in smart cities, *IEEE Transactions on Intelligent Transportation Systems*, Vol. 23, No. 11, pp. 22619–22629 (2021).
- [7] JamieO’ Sullivan, DominicO’ Sullivan, Bruton, K.: A case-study in the introduction of a digital twin in a large-scale smart manufacturing facility, *Procedia Manufacturing*, Vol. 51, pp. 1523–1530 (2020).
- [8] Wang, R., Zhou, X., Dong, L., Wen, Y., Tan, R., Chen, L., Wang, G. and Zeng, F.: Kalibre: Knowledge-based neural surrogate model calibration for data center digital twins, *Proceedings of the 7th ACM International Conference on Systems for Energy-Efficient Buildings, Cities,*

- and Transportation, pp. 200–209 (2020).
- [9] Li, M., Wang, R., Zhou, X., Zhu, Z., Wen, Y. and Tan, R.: ChatTwin: Toward Automated Digital Twin Generation for Data Center via Large Language Models, *Proceedings of the 10th ACM International Conference on Systems for Energy-Efficient Buildings, Cities, and Transportation*, BuildSys '23, pp. 208–211 (online), 10.1145/3600100.3623719 (2023).
 - [10] Min, Q., Lu, Y., Liu, Z., Su, C. and Wang, B.: Machine learning based digital twin framework for production optimization in petrochemical industry, *International Journal of Information Management*, Vol. 49, pp. 502–519 (2019).
 - [11] Elayan, H., Aloqaily, M. and Guizani, M.: Digital twin for intelligent context-aware IoT healthcare systems, *IEEE Internet of Things Journal*, Vol. 8, No. 23, pp. 16749–16757 (2021).
 - [12] Chen, Y., Wang, W., Diao, J., Wang, D., Jian, Z., Wang, Y. and Jiang, Z.: Digital-Twin-Based Patient Evaluation during Stroke Rehabilitation, *Proceedings of the ACM/IEEE 14th International Conference on Cyber-Physical Systems (with CPS-IoT Week 2023)*, ICCPS '23, pp. 22–33 (online), 10.1145/3576841.3585923 (2023).
 - [13] Das, T., Wang, Z. and Sun, J.: TWIN: Personalized Clinical Trial Digital Twin Generation, *Proceedings of the 29th ACM SIGKDD Conference on Knowledge Discovery and Data Mining*, KDD '23, pp. 402–413 (online), 10.1145/3580305.3599534 (2023).
 - [14] Fortino, G. and Savaglio, C.: Integration of digital twins & internet of things, *The Digital Twin*, pp. 205–225 (2023).
 - [15] Rudskoy, A., Ilin, I. and Prokhorov, A.: Digital twins in the intelligent transport systems, *Transportation Research Procedia*, Vol. 54, pp. 927–935 (2021).
 - [16] Kumar, S. A., Madhumathi, R., Chelliah, P. R., Tao, L. and Wang, S.: A novel digital twin-centric approach for driver intention prediction and traffic congestion avoidance, *Journal of Reliable Intelligent Environments*, Vol. 4, No. 4, pp. 199–209 (2018).
 - [17] Kaigom, E. G. and Roßmann, J.: Value-driven robotic digital twins in cyber-physical applications, *IEEE Transactions on Industrial Informatics*, Vol. 17, No. 5, pp. 3609–3619 (2020).
 - [18] Saracco, R.: Digital twins: Bridging physical space and cyberspace, *Computer*, Vol. 52, No. 12, pp. 58–64 (2019).
 - [19] Said, A., Berkovsky, S. and De Luca, E. W.: Group recommendation in context, *Proceedings of the 2nd challenge on context-aware movie recommendation*, pp. 2–4 (2011).
 - [20] Senot, C., Kostadinov, D., Bouzid, M., Picault, J., Aghasaryan, A. and Bernier, C.: Analysis of strategies for building group profiles, *International Conference on User Modeling, Adaptation, and Personalization*, pp. 40–51 (2010).
 - [21] Webster, J. G. and Wakshlag, J. J.: The impact of group viewing on patterns of television program choice, *Journal of Broadcasting & Electronic Media*, Vol. 26, No. 1, pp. 445–455 (1982).
 - [22] Bjur, J.: *Transforming audiences. Patterns of individualization in television viewing*, No. 1101-4652, Department of Journalism and Mass Communication; Institutionen för journalistik och masskommunikation (2009).
 - [23] Rust, R. T., Kamakura, W. A. and Alpert, M. I.: Viewer preference segmentation and viewing choice models for network television, *Journal of advertising*, Vol. 21, No. 1, pp. 1–18 (1992).
 - [24] Gim, G., Jeong, H., Lee, H. and Yun, D.: Group-aware prediction with exponential smoothing for collaborative filtering, *Proceedings of the 2nd Challenge on Context-Aware Movie Recommendation*, pp. 11–14 (2011).
 - [25] Gorla, J., Lathia, N., Robertson, S. and Wang, J.: Probabilistic group recommendation via information matching, *Proceedings of the 22nd international conference on World Wide Web*, pp. 495–504 (2013).
 - [26] Hu, X., Meng, X. and Wang, L.: Svd-based group recommendation approaches: an experimental study of moviepilot, *Proceedings of the 2nd challenge on context-aware movie recommendation*, pp. 23–28 (2011).
 - [27] Chaney, A. J., Gartrell, M., Hofman, J. M., Guiver, J., Koenigstein, N., Kohli, P. and Paquet, U.: A large-scale exploration of group viewing patterns, *Proceedings of the ACM International Conference on Interactive Experiences for TV and Online Video*, TVX '14, pp. 31–38 (online), 10.1145/2602299.2602309 (2014).
 - [28] Tavakoli, M. and Cave, M.: Modelling Television Viewing Patterns, *Journal of Advertising*, Vol. 25, No. 4, pp. 71–86 (online), 10.1080/00913367.1996.10673513 (1996).
 - [29] 松田裕貴, 榊原太一, 水本旭洋, 安本慶一ほか: 放送局を横断する大規模テレビ視聴履歴データの統合手法の提案と実践, 情報処理学会論文誌デジタルプラクティス (TDP), Vol. 4, No. 1, pp. 34–44 (2023).
 - [30] 松田裕貴, 榊原太一, 真弓大輝, 松田裕貴, 水本旭洋, 安本慶一: 非特定テレビ視聴履歴データの放送局間統合手法, 情報処理学会論文誌, Vol. 65, No. 10, pp. 1488–1500 (オンライン), 10.20729/00239892 (2024).
 - [31] 松田裕貴, 榊原太一, 木俣雄太, 鳥羽望海, 真弓大輝, 松田裕貴, 安本慶一: テレビ視聴における非特定視聴履歴データとインターネット検索データの関係性分析, 第 14 回データ工学と情報マネジメントに関するフォーラム (DEIM '22), pp. 1–6 (2022).
 - [32] 吉村啓, 水本旭洋, 榊原太一, 松田裕貴: テレビ視聴時の CM 離脱と地域傾向分析, 人工知能と知識処理研究会, Vol. 121, pp. 43–48 (2022).